

UNITECH

Projet IA2

Niveau 3 et 4 Sces
Info.

Prof. Ing. Micanord Mulâtre

1. Contexte

Dans le cadre du Nouveau Secondaire en Haïti, les élèves peuvent être orientés vers différentes séries, notamment **SMP, SVT, SES et LLA**.

L'objectif de ce projet est de développer un **système intelligent d'aide à l'orientation scolaire** capable d'analyser le profil académique et certains centres d'intérêt d'un élève afin de proposer la série qui correspond le mieux à son profil.

Le système devra utiliser des techniques de **Machine Learning** et être accessible à travers une **interface graphique développée avec PyQt**.

Important : le système développé constitue un outil d'aide à la décision. Il ne doit pas être considéré comme un dispositif officiel d'orientation scolaire.

2. Objectif général

Développer une application capable de :

1. charger et préparer un jeu de données d'élèves ;
2. analyser et nettoyer les données ;
3. effectuer les encodages nécessaires ;
4. entraîner plusieurs modèles de classification ;
5. comparer leurs performances ;
6. sélectionner le modèle le plus approprié ;
7. sauvegarder le modèle avec `Joblib` ;
8. charger le modèle dans une application PyQt ;
9. saisir le profil d'un nouvel élève ;
10. prédire la série la plus compatible avec son profil.

Les séries à prédire sont :

- **SMP** — Sciences, Mathématiques et Physique ;
- **SVT** — Sciences de la Vie et de la Terre ;
- **SES** — Sciences Économiques et Sociales ;
- **LLA** — Lettres, Langues et Arts.

3. Jeu de données

Un jeu de données simulé de **3 000 élèves** est fourni avec le projet.

Le fichier contient notamment :

- les notes scolaires ;
- le niveau de motivation ;
- le centre d'intérêt ;
- l'intérêt pour l'informatique ;
- l'aptitude logique ;
- la moyenne générale ;
- la série cible.

Le dataset contient volontairement des **valeurs manquantes et quelques valeurs anormales**. Les étudiants devront donc effectuer un travail de préparation avant l'entraînement du modèle.

4. Travail demandé

Partie A — Exploration des données

À l'aide de Pandas, effectuer une analyse exploratoire du dataset.

Vous devrez notamment :

- afficher les dimensions du dataset ;
- afficher les premières et dernières lignes ;
- identifier les types de données ;
- calculer les statistiques descriptives ;
- identifier les valeurs manquantes ;
- identifier les éventuelles valeurs aberrantes ;
- analyser la répartition des quatre séries.

Présentez quelques observations permettant de comprendre le dataset.

Partie B — Prétraitement

Préparer les données pour l'apprentissage automatique.

Vous devrez notamment :

- traiter les valeurs manquantes ;
- identifier et traiter les valeurs aberrantes ;
- séparer les variables explicatives de la variable cible ;
- effectuer les encodages nécessaires.

Vous devrez distinguer les différents types de variables :

- variables numériques ;
- variables binaires ;
- variables ordinales ;
- variables catégorielles.

Attention : l'identifiant de l'élève ne doit pas être utilisé comme variable prédictive.

Partie C — Construction des modèles

Entraîner **au minimum trois algorithmes de classification** parmi les suivants :

- Logistic Regression ;
- Decision Tree ;
- Random Forest ;
- K-Nearest Neighbors ;
- Support Vector Machine.

Utilisez une séparation appropriée entre les données d'entraînement et les données de test.

Vous devrez expliquer brièvement pourquoi les modèles choisis sont adaptés au problème.

Partie D — Évaluation et comparaison

Évaluer les différents modèles à l'aide de plusieurs métriques, notamment :

- Accuracy ;
- Precision ;
- Recall ;
- F1-score ;
- matrice de confusion.

Présentez les résultats dans un tableau comparatif.

Exemple :

Modèle	Accurac y	Precisio n	Recal l	F1- scor e

Logistic Regressio n	...	...	...	...
Decision Tree	...	...	...	...
Random Forest	...	...	...	...

Sélectionnez ensuite le modèle que vous considérez comme le plus approprié et **justifiez votre choix**.

Partie E — Sauvegarde du modèle

Le modèle sélectionné devra être sauvegardé à l'aide de la bibliothèque `Joblib`.

Exemple :

```
joblib.dump(model, "modele_orientation.joblib")
```

L'application finale devra pouvoir charger ce modèle sans effectuer de nouvel entraînement.

5. Développement de l'application PyQt

Développez une interface graphique permettant à un utilisateur de saisir les informations d'un nouvel élève.

L'interface devra permettre de renseigner au minimum :

- note de mathématiques ;
- note de physique ;
- note de SVT ;
- note de français ;
- note d'histoire ;
- niveau de motivation ;
- centre d'intérêt ;
- intérêt pour l'informatique ;
- aptitude logique.

La moyenne générale pourra être calculée automatiquement à partir des notes saisies.

6. Résultat de l'orientation

Après validation du formulaire, l'application devra :

1. récupérer les données saisies ;
2. appliquer exactement le même prétraitement que celui utilisé lors de l'entraînement ;
3. charger le modèle `Joblib` ;
4. effectuer la prédiction ;
5. afficher la série recommandée.

Exemple de résultat attendu :

```
=====
                        RÉSULTAT DE L'ORIENTATION
=====

SMP : 86 %
SVT : 72 %
SES : 43 %
LLA : 27 %

Série recommandée : SMP
```

Lorsque le modèle utilisé permet d'obtenir les probabilités, celles-ci devront être affichées.

7. Organisation technique recommandée

Le projet pourra être organisé de la manière suivante :

```
projet_orientation/
├── data/
│   └── dataset_orientation_NS_3000.csv
├── model/
│   └── modele_orientation.joblib
├── train.py
├── evaluation.py
├── preprocessing.py
├── application.py
└── README.md
```

Les étudiants sont libres d'adopter une autre organisation à condition que le projet soit correctement structuré.

8. Contraintes techniques

Le projet devra obligatoirement utiliser :

- **Python**
- **Pandas**
- **NumPy**
- **Scikit-learn**
- **Joblib**
- **PyQt**

L'application devra fonctionner **localement**, sans API et sans connexion Internet.

9. Livrables

Chaque groupe devra remettre :

1. Le code source

L'ensemble des fichiers Python nécessaires au fonctionnement du projet.

2. Le modèle entraîné

Le fichier :

`modele_orientation.joblib`

3. Le rapport

Le rapport devra présenter :

- le contexte et la problématique ;
- une description du dataset ;
- l'analyse exploratoire ;
- les traitements effectués ;
- les techniques d'encodage utilisées ;
- les modèles testés ;
- les métriques obtenues ;
- la comparaison des modèles ;
- le modèle retenu et la justification ;
- quelques captures de l'application PyQt ;
- les limites du système ;

- une conclusion.

4. README

Un fichier `README.md` expliquant :

- comment installer les dépendances ;
- comment entraîner le modèle ;
- comment lancer l'application ;
- comment utiliser le système.

10. Travail en équipe

Le projet peut être réalisé en **groupes de 3 à 5 étudiants**.

Les membres du groupe devront répartir clairement les responsabilités, par exemple :

- préparation et analyse des données ;
- développement et évaluation des modèles ;
- développement de l'interface PyQt ;
- intégration et documentation.

Chaque membre devra être capable d'expliquer l'ensemble du fonctionnement du projet lors de la présentation.

11. Bonus

Les fonctionnalités suivantes pourront donner lieu à des points supplémentaires :

- affichage graphique des probabilités ;
- affichage de l'importance des variables ;
- possibilité de réinitialiser le formulaire ;
- validation des données saisies ;
- historique des orientations ;
- utilisation de SQLite ;
- comparaison visuelle des performances des modèles ;
- affichage d'une explication simple de la recommandation ;
- amélioration de l'ergonomie de l'interface.

12. Question centrale du projet

À travers ce projet, vous devrez répondre à la question suivante :

« Peut-on utiliser les performances scolaires, les centres d'intérêt et certaines aptitudes d'un élève pour construire un modèle de Machine Learning capable de proposer la série du Nouveau Secondaire la plus compatible avec son profil ? »

Votre travail devra démontrer **non seulement que le modèle peut effectuer une prédiction, mais également que vous comprenez les données, les limites du modèle et les conditions nécessaires pour utiliser une telle prédiction dans un contexte éducatif.**

Remarque importante : le dataset fourni est simulé à des fins pédagogiques. Les résultats obtenus ne doivent pas être interprétés comme une validation scientifique d'une méthode réelle d'orientation des élèves en Haïti.

Délai

- Date de début : **27 août 2026**
- Date limite : **08 septembre 2026 à 12h00 PM**